

PAUL MICKY D COSTA

INGÉNIEUR LOGICIEL ET SCIENTIFIQUE DES DONNÉES

Adresse: 37 Avenue Berlioz, 93270 Sevrans, France

Téléphone: +33 665225305 / +45 50371225

Courriel: pmdcosta01@gmail.com

Site web: <https://paulmickydcosta.com>

LinkedIn: /in/paul-micky-d-costa

GitHub: /paulmicky1

Informations suppl.: Fiable, systématique, détaillé et logique

Communication et langues: Anglais: courant (C1) Français: (A2)

RÉSUMÉ

J'apporte de la **valeur métier** — pas seulement de la technique. Grâce à une **double culture IT et business**, je **comprends ce dont les utilisateurs ont besoin**, je parle leur langage et je **construis des solutions** centrées sur eux. Je travaille directement avec les utilisateurs finaux, j'écoute leurs problèmes et je les traduis en outils intuitifs, utiles et adoptés. Je conçois en gardant le business en tête : chaque tableau de bord, application ou automatisation que je livre est façonné par des cas d'usage réels et un impact mesurable. Je **monte rapidement en compétence sur n'importe quel outil**, je **maintiens ce que je construis** et je crée proactivement des solutions — pour les utilisateurs, les collègues et l'organisation — même sans qu'on me le demande. Ma force réside à l'intersection de **la data science, du génie logiciel et de la compréhension métier** : transformer des capacités techniques complexes en valeur concrète et durable.

J'ai acquis une expérience pratique dans le soutien des processus numériques liés à la **Qualité, Santé, Sécurité, Environnement et Sûreté (QHSES)** et à la **gestion des risques** au sein d'une organisation d'ingénierie mondiale. J'ai produit des **Documents d'Architecture de Référence Produit (PAR)**, des business cases, des feuilles de route produit, des supports de formation et des présentations exécutives pour soutenir l'adoption des produits et la prise de décision. J'ai travaillé dans un environnement international avec des parties prenantes issues de multiples fonctions et géographies (**Business et Digiteam**).

ÉDUCATION

Master en informatique et science des données ESILV - École Supérieure d'Ingénieurs Léonard de Vinci, France	2025–2026
Bachelor of Science avec mention Très Bien en Informatique Académie internationale des affaires (IBA) (certifiée par l'université de Coventry), Kolding, Danemark	2024–2025
Licence en informatique et ingénierie Université indépendante, Bangladesh (IUB), Dhaka, Bangladesh	2018–2023
General Certificate of Education — Advanced Subsidiary Level & Advanced Level (A-Levels)	2015–2017
International General Certificate of Secondary Education (IGCSE) / General Certificate of Education — Ordinary Level (O-Levels)	2014

EXPÉRIENCE PROFESSIONNELLE

Chargé des Systèmes d'Information QHSES Global (Stagiaire) Technip Energies	30 mai 2026 – 25 septembre 2026
--	---------------------------------

- Collaboration directe avec les **parties prenantes QHSES** pour recueillir les besoins métier, valider les cas d'usage et concevoir itérativement une solution alignée sur les processus de gestion des risques opérationnels

— aboutissant à la plateforme **Intelix × RMA** (Risk Management Application). Rédaction d'un **document PARD**, présentations utilisateurs, documents de valeur métier et feuilles de route pour un public non-technique.

- Développement de l'**application RTA (Real Time Alert)** pour l'**équipe Sécurité Global** : ingestion automatisée de sources d'actualités en direct, **alertes email immédiates** aux adresses de l'entreprise, rapports digest toutes les 6 heures et **tableau de bord interactif avec géolocalisation des incidents sur carte**.
- Automatisation complète du **tableau de bord Qualité Global Power BI** en remplaçant les flux Excel manuels par une connexion directe à la base de données (**SpotDB**), **éliminant la saisie manuelle** et livrant un **tableau de bord Qualité mondial en temps réel**.
- **Administration de la plateforme TEN Alert** pour le **Département Sécurité Global** : gestion des accès et des permissions, résolution des problèmes utilisateurs, communication avec les utilisateurs de la plateforme et **maintien des systèmes de surveillance ITIL** avec suivi des incidents et résolution dans les délais.
- Développement d'un bot administrateur Hybrid RAG dans **Dataiku** pour assister les administrateurs de la plateforme dans leurs requêtes opérationnelles.
- Collaboration au sein de l'**équipe QHSES Digital** — **rédaction de BR**, accompagnement des collègues, évaluation des plateformes, création de présentations et rédaction de comptes-rendus de réunion.
- Suivi de la **formation T.ENET** (programme interne Technip Energies), avec développement de livrables de projet formellement **examinés et approuvés** par l'organisation — actuellement **en attente** de décisions internes complémentaires.

Développeur front-end | Tech Trio Solutions

février 2023 – juin 2023

- Conception et mise en œuvre de prototypes UI/UX à l'aide de Figma.
- Développement d'applications à l'aide de Vue3 sur des environnements Linux.
- Gestion du contrôle de version à l'aide de GitHub.
- Production de la documentation essentielle au projet (diagrammes de Gantt, organigrammes, rapports techniques).
- Projets clés : développement de « Shahajjo », une plateforme de services en ligne, et d'un système de suivi des employés pour Grameenphone.

CERTIFICATIONS

- Advanced Designer Certificate (Dataiku)
- Core Designer Certificate (Dataiku)
- Developer Certificate (Dataiku)
- Generative AI Practitioner Certificate (Dataiku)
- MLOps Practitioner Certificate (Dataiku)
- ML Practitioner Certificate (Dataiku)
- Formation T.ENET — programme interne Technip Energies

PROJETS LIÉS À LA SCIENCE DES DONNÉES ET AUX LOGICIELS

Projets Dataiku & BI (Technip Energies)

TEN — Application Intelix × RMA - Dataiku, FastAPI, JavaScript, Pandas, Chart.js, Azure GPT-5.2

Application web intégrant les retours Intelix (via API REST) à la base de données RMA pour classifier automatiquement les risques en quatre catégories : risque identifié avec retour ; risque identifié sans retour ; risque non identifié avec retour survenu ; aucun risque défini (génération automatique de risques par IA). Interface à 11 onglets avec 6 KPI, moteur de correspondance sémantique TF-IDF, graphiques interactifs, recherche en temps réel, export Excel et assistant IA GPT-5.2. Rédaction d'un **document PARD**, présentations, documents de valeur métier et feuilles de route pour un public non-technique.

Visualisation 3D du portefeuille de projets QHSES - Three.js, JavaScript, Dataiku

Conception et développement d'une visualisation de réseau 3D interactive déployée comme webapp Dataiku, représentant le portefeuille de projets Qualité, Santé, Sécurité, Environnement et Sûreté de l'équipe QHSES Digital sous forme de graphe navigable de type neuronal avec des impulsions animées. Navigation par clic reliant chaque

nœud à son tableau de bord en direct, sa documentation SharePoint et son flow Dataiku, à l'aide d'un rendu 3D personnalisé (contrôles caméra, raycasting, connecteurs courbes dynamiques) plutôt que des bibliothèques de graphiques standards.

RealTimeAlerts - Pipeline automatisé de veille sécurité et d'actualités - Dataiku DSS, Python, Azure OpenAI (GPT-5.2), Apify, NewsAPI, FastAPI, Leaflet.js, Chart.js

Conception d'un système automatisé de veille des menaces de bout en bout sur Dataiku combinant l'ingestion NewsAPI/Apify (configuration CSV modifiable par les métiers), un tri à deux facteurs par GPT-5.2 via le LLM Mesh de Dataiku, une déduplication basée sur les URL et des notifications à plusieurs niveaux (alertes email SMTP, digests PDF reportlab programmés, archivage Azure Blob Storage). Automatisation complète via les Scénarios Dataiku pour un fonctionnement 24/7, avec un tableau de bord FastAPI/Leaflet.js/Chart.js pour la géolocalisation et les flux d'actualités, ainsi qu'une analyse coûts-bénéfices présentée aux parties prenantes.

Automatisation des synthèses exécutives d'audit - Dataiku DSS, Flask, Azure OpenAI (GPT-4o), API REST Intalex (OData v2)

Développement d'une solution IA sur Dataiku qui récupère les audits Intalex via son API OData v2 et utilise GPT-4o pour générer des synthèses exécutives structurées (évaluation des risques, thèmes clés, risques critiques, recommandations). Livrée sous forme d'application web Flask en self-service et d'une recette de traitement par lot avec gestion d'erreurs ligne par ligne, appuyée par un document de spécifications fonctionnelles complet pour validation des parties prenantes.

Analyse de sentiment des avis hôteliers TripAdvisor et insights GenAI - Dataiku DSS, recettes GenAI, LLM Mesh (GPT-4o), Agents IA visuels

Développement d'un pipeline GenAI de bout en bout dans Dataiku utilisant des recettes Classification/Synthèse/Prompt pour l'analyse de sentiment, le résumé et la traduction multilingue des avis hôteliers, ainsi qu'un outil d'agent personnalisé pour la recherche par mots-clés et un agent IA visuel permettant l'interrogation en langage naturel du jeu de données d'avis.

Tableau de bord Qualité Global - Power BI, SpotDB, TypeScript, Power Automate

Automatisation complète du tableau de bord Qualité mondial en migrant des flux Excel manuels vers une connexion directe à la base de données SpotDB, éliminant la saisie manuelle. Scripts TypeScript pour la transformation des données et flux Power Automate pour déclencher actualisations et alertes, livrant un tableau de bord Qualité global en temps réel accessible à l'ensemble de l'organisation.

Systèmes distribués et pipeline de données en temps réel

Pipeline de données météorologiques en temps réel - Kafka, Spark, Hadoop, Azure, InfluxDB, Grafana

Conception et mise en œuvre d'un pipeline de données multi-nœuds et évolutif sur des machines virtuelles Azure Linux (maître/esclave) pour l'ingestion de données en temps réel. Utilisation d'Apache Kafka pour l'ingestion d'API (OpenAPI 3.0), de Hadoop/PySpark (YARN) pour le traitement distribué et stockage des données chronologiques dans InfluxDB (PostgreSQL pour les données structurées). Visualisation des métriques dans Grafana.

RAG & Systèmes LLM locaux

Chatbot médical RAG - Python, ChromaDB, Sentence-Transformers, Ollama (Mistral Nemo), HuggingFace

Développement d'un système RAG (Retrieval-Augmented Generation) entièrement local répondant à des questions médicales en récupérant du contexte sémantiquement pertinent parmi 33 955 paires Q&R; médicales (dataset medical_meadow_medical_flashcards). Les embeddings sont générés avec all-MiniLM-L6-v2 et indexés dans ChromaDB ; au moment de la requête, les 5 enregistrements les plus similaires sont injectés comme contexte dans Mistral Nemo (servi via Ollama) qui génère une réponse en streaming. Le pipeline tourne entièrement en local, sans appel d'API externe, adapté aux données médicales sensibles.

Apprentissage automatique et prévisions

Analyse des campagnes Criteo (prédiction et optimisation du CTR) - Projet d'apprentissage automatique
Projet d'apprentissage automatique axé sur la prédiction et l'optimisation du taux de clics (CTR) des publicités Criteo à l'aide de modèles Random Forest.

Analyse des dépenses publiques françaises (prévisions 1995-2030) - Analyse des données et prévisions

Analyse et prévisions basées sur les données des dépenses publiques françaises à l'aide de modèles de régression et d'outils de visualisation afin de prédire les tendances jusqu'en 2030.

OSINT et renseignement de sécurité

Global Risk Watch (globalriskwatch.paulmickydcosta.com) - Plateforme de surveillance des risques géopolitiques en temps réel - Node.js, Express, D3.js, Cloudflare (DNS/Tunnel), NSSM

Plateforme full-stack développée en solo, de bout en bout, agrégeant des données d'actualités mondiales en direct et des données publiques de sécurité dans une carte du monde interactive avec scoring de risque par pays, graphes de relations transfrontalières et couches de données par rôle. Conception d'un pipeline de données en direct ingérant plus de **80 000 événements quotidiens** depuis l'API publique de **GDELT**, calculant un score de risque pondéré (ratio de conflit, sentiment, volume d'événements) et des graphes de relations transfrontalières par pays quasiment en temps réel. Intégration de l'API publique **Red Notices d'INTERPOL** — en contournant sa couche de protection anti-bot — pour construire une couche de données sur les personnes recherchées avec récupération de détails à la demande et mise en cache locale, ainsi qu'un pipeline de classification de texte côté serveur (recherche par mots-clés puis vérification locale sur le texte complet des dossiers) pour dériver deux catégories de données supplémentaires à partir de données de charges non structurées, en minimisant les faux positifs. Développement d'une couche de visualisation interactive en **D3.js** : carte du monde projetée avec bulles de risque dynamiques, arcs de relation courbes, marqueurs d'événements géocodés et filtrage en direct sur plusieurs dimensions de données. Mise en place de l'authentification et du renforcement de la sécurité — authentification par session avec comparaison d'identifiants en temps constant et verrouillage anti-force brute, Content-Security-Policy stricte, et correction d'une vulnérabilité XSS persistante sur plus de 20 chemins de rendu — puis déploiement en production sur une infrastructure autogérée : migration du DNS vers **Cloudflare**, configuration d'un **Cloudflare Tunnel** pour un accès HTTPS public sans aucun port entrant ouvert, et mise en place de services Windows à redémarrage automatique pour une disponibilité continue.

France Situational Awareness Monitor (monitor.paulmickydcosta.com) - Node.js, Express, D3.js, Chart.js, API Anthropic Claude, RSS/Atom/XML, analyse HTML, JavaScript

Développement d'un tableau de bord OSINT de veille des menaces, auto-hébergé et full-stack, agrégeant en temps réel des actualités, vidéos et contenus de réseaux sociaux issus de **plus de 27 sources ouvertes** (flux RSS/Atom, chaînes YouTube, chaînes Telegram publiques). Conception d'un **moteur de classification bilingue (FR/EN) basé sur des règles** (~45 signaux de menace, ~25 signaux de pertinence pour la France, gazetier d'environ 120 localités) pour étiqueter automatiquement les articles par catégorie, niveau de menace et origine géographique. Intégration de l'**API Anthropic Claude** pour générer des briefings de menace structurés par IA (justification de la menace, indicateurs clés, actions de réponse, évaluation de l'urgence) via une file d'attente de traitement asynchrone avec mise en cache par élément pour maîtriser le coût d'API. Développement de visualisations interactives avec **D3.js** (carte du monde avec marqueurs géoprojetés, graphe de co-occurrence à disposition dirigée par les forces) et **Chart.js** (tableaux de bord par catégorie/chronologie/source), servies via une API REST à une application monopage en JavaScript pur avec filtrage en direct, recherche et actualisation automatique. Mise en place d'une dégradation progressive et d'une logique de nouvelle tentative en cas d'échec des API tierces.

Développement d'applications

Buddy — Avatar IA personnel (buddy.paulmickydcosta.com) - IA conversationnelle, RA, Meta Quest 3 Pro, Web

Développement et déploiement d'un avatar IA personnel accessible sur buddy.paulmickydcosta.com. Les visiteurs peuvent tenir une conversation en direct avec l'avatar et le visualiser en temps réel. Expérience étendue en Réalité Augmentée via le Meta Quest 3 Pro — donnant vie à l'avatar dans l'espace physique pour une interaction immersive et réaliste qui transcende l'interface écran classique. Démonstrations publiées en YouTube Shorts : youtube.com/@PaulDCosta-l7g/shorts.

COMPÉTENCES TECHNIQUES

Analyses avancées et IA

Apprentissage profond avancé : traitement du langage naturel (NLP), vision par ordinateur.

Systèmes graphiques et exploration de données : expertise dans les concepts de bases de données graphiques et l'analyse de réseaux.

Visualisation immersive des données / analyse visuelle : création de solutions de visualisation interactives, exploratoires et immersives.

Extraction de données Web et traitement des données

Big Data et processus distribués : **Apache Spark, PySpark (YARN), Hadoop**.

Outils de scraping et de traitement : **Python, Scala, BeautifulSoup**.

Expertise : **conception de pipelines évolutifs pour l'ingestion d'API en temps réel (OpenAPI 3.0) et le scraping web complexe.**

Bases de données, BI et MLOps

Opérations d'apprentissage automatique (MLOps) : **pipelines CI/CD (Jenkins, Docker, SonarQube) pour des déploiements automatisés et reproductibles.**

Business Intelligence (BI) : **Power BI, Grafana (tableaux de bord en temps réel).**

Stockage des données : **PostgreSQL (PgAdmin), InfluxDB (séries chronologiques), MongoDB, Superbase, SpotDB, DataGalaxy.**

Cloud et environnement : **Microsoft Azure, AWS (machines virtuelles Linux), VM Linux Ubuntu/Kali, Jupyter/Colab, Dataiku DSS.**

Compétences en sécurité, IA et durabilité

Mesure de la durabilité : évaluation et reporting des indicateurs de performance durabilité/QHSE.

Sécurité Web : **cookies de sécurité, authentification et gestion des mots de passe, hacking éthique.**

IA générative : **génération augmentée par récupération (RAG), gestion des clés d'API, entraînement et développement de nouveaux modèles ML/IA, LLM Mesh et Agents IA visuels (Dataiku).**

Outils de sécurité et logiciels

Microsoft Threat Modeling Tool, OWASP ZAP, SonarQube.

Plateformes low-code et automatisation

Dataiku DSS : **pipelines de données de bout en bout, recettes GenAI, LLM Mesh, Agents IA visuels, Scénarios et webapps Dataiku (Flask/FastApi/Three.js/Chart.js).**

Power Automate : **automatisation des flux de travail et déclenchement d'actualisations/alertes.**

Communication et documentation

Création de **présentations (PowerPoint)** pour le suivi de projets et la communication avec les parties prenantes.

Rédaction de comptes-rendus de réunion et de documents de Business Requirements (BR).

Ingénierie de base

Langages : Python, C#, C++, Java, Bash, Scala, SQL.

Web/Front-End : HTML, CSS, JavaScript, Vue.js, React, Node.js.

Outils : VSCode, Cursor, Git, GitHub, Cisco, **InteleX, SharePoint Online, Microsoft 365, Copilot, TopoOne, TEN Alert, GardaWorld Travel Security, RMA, DragonFly.**

Plateformes low-code/data : Dataiku DSS, Power Automate.

Big Data et distribution : Apache Spark, PySpark (YARN), Hadoop, Apache Kafka

Cloud et infrastructure : Microsoft Azure, AWS (machines virtuelles Linux), Docker, VM Linux Ubuntu, Kali Linux

Stockage de données et BI : PostgreSQL (PgAdmin), InfluxDB (séries chronologiques), MongoDB, Superbase, SpotDB, DataGalaxy, Power BI, Grafana

MLOps et CI/CD : **Jenkins, SonarQube, n8n, MLflow, Docker Compose, PyTest**

Analytique avancée et IA : Apprentissage profond avancé, traitement du langage naturel (NLP), vision par ordinateur, systèmes graphiques et exploration de données, visualisation immersive des données, analyse visuelle, BeautifulSoup, Generative AI (LLMs)

Plateformes de science des données : **Jupyter Notebooks, Google Colab**